# Mongodb 针对复杂查询的特性

## 场景: 计费话单查询

#### 计费话单条件查询

#### 如上图所示:

- 查询条件: 企业ID: 880001, 主叫: 290727, 被叫: 1369, 入局,中继: cop, 外线号: 0551, 时间范围: 2019-01-21 -- 2019-2-21
- 分页数量为 15条
- 扫描数据量为3511273 个文档,3511273 个索引
- 查询到的数据为 0 条
- 耗时 20.45秒

#### 查询慢的原因

- 查询条件多,需要过滤的文档多,导致扫描数据大
- 没有命中排序索引,需要排序的数据量大
- 索引选举耗时的耗时

#### 优化思路:

- 分表: 尽可能地使扫描数据记录减少
- 分词:把模糊查询优化成,分词匹配,确保索引能够精确命中(模糊查询会扫描所有的索引记录)
- 保证内存空间:确保索引都在内存中扫描

## 针对 mongodb 的查询效率优化总结

- 扫描索引和文档越多, 耗时也越多
- 机器内存大小,影响查询效率

## 优化建议如下:

### 查询数量

- 使用近似值 (explain 中预测扫描行的数量)
- 简到优化(总数-已知小分数据的数量)
- 覆盖索引优化
- 汇总表/外部缓存数量(存储数量的数据)

## 对于复杂的模糊查询

#### • 索引优化策略

o *创建索引以支持查询* 

当索引包含了查询的所有键时,索引可以支持该查询。创建可以支持查询的索引会带来极大的查询性能提升。

#### 使用索引来排序查询结果

为了支持高效的查询,当您需要指定被索引键的排列顺序和排序顺序时,请使用此处的策略。

#### 确保索引与内存相适应

当您的索引可以整个存储于内存时,系统可以避免从磁盘读取索引,这时您的处理过程会变得更快。

#### 创建能确保选择力的查询

选择力是查询使用索引来缩窄结果集范围的能力。选择力使得MongoDB可以使用索引来完成匹配查询过程中的更多工作

#### • 排序优化

- o 按照指定索引顺序进行排序
- 尽量做到读写分离
- 索引,集合加载到内存
  - o 预加载数据或者索引到内存: db.runCommand({ touch: "collectionName", data: [true|false], index: [true|false] })

#### • 查询方式优化

- 。 使得索引命中率提升
- 。 缩小查询数据结果集的范围
- 。 模糊查询尽量使用字段数据分词
- · 业务分离,能抽出来的业务,尽可能少去查询数据量大的数据表

#### • 数据结构优化

- 。 如查询方式优化
- 。 分表
- o 分库

## 计费话单优化方案

#### 1 查询方式优化

查询条件优化 (呼叫,被叫,外线号码 三选一查询)

原因: 因为三个字段都是单独的索引,减少索引选举和文档比较的次数

#### 2索引调整

#### 旧索引列表

```
"_id_" : 242565120,

"callRecord_tenementId_beginTime_endTime_idx" : 347521024,

"callRecord_beginTime_endTime_tenementId_idx" : 536272896,

"tenementId" : 82497536,

"direction" : 83247104,

"trunkId" : 82489344,

"monthSetId" : 83300352,

"callRecord_direction_trunkId_idx" : 85852160,

"callRecord_beginTime_tenementId_idx" : 261197824
}
```

#### 优化后的索引

```
{
    "_id_" : 437186560,
    "monthSetId_1" : 448692224,
    "beginTime_-1" : 526671872,
    "duration_1_beginTime_-1" : 244002816,
    "trunkId_1_beginTime_-1" : 148099072,
    "calling_arr_1_beginTime_-1" : 149823488,
    "called_arr_1_beginTime_-1" : 448135168,
    "wireNumber_arr_beginTime_-1" : 147931136,
}
```

#### 3 模糊查询字段进行分词

```
* **分词后的数据结构**
* **使用查询前缀查询**(默认索引前缀匹配)
```

```
{
    "_id" : ObjectId("5b23db5faeee1022a08b8e8a"),
    "_class" : "com.ejiahe.bms.bean.mongobean.CallRecord",
    "tenementId" : "880001",
    "callingNumID" : "249999",
    "calledNumID" : "4444",
    "callingUserId" : "u110002",
    "calledUserId" : "",
```

```
"direction" : "inner",
   "beginTime" : NumberLong("1529076539000"),
   "endTime" : NumberLong("1529076551000"),
   "duration" : 12,
   "billuserId" : "u110002",
   "calledRes" : "OK",
   "calling" : "249999(249999)",
   "called" : "4444",
   "wireNumber":"12345",
   "calling_arr":['24','99','2499','24999','249999'],
   "called_arr":['44','444','4444'],
   "wireNumber_arr":['12','23','34','45','123','234','345','1234','2345'],
   "durationTime" : "00:00:12",
   "createTime" : NumberLong("1529076575673")
}
```

#### 4 按月分表

- 按月分表查询(分页尽量避免跨月操作)
- 根据时间进行分页查询,减少扫描数据量

#### 5 保证足够内存

• 当前德邦 mongdb 内存中的数据状况

• 当前德邦 mongodb 实际存储数据状况

## 左缀索引和分词比较 (基于本地数据库进行比较)

## 建立索引速度



结果显示: 索引创建结果相差不大

### 数据准备

- 左前缀: 无需修改数据, 只是添加索引即可
- 分词: 需要额外,对模糊查询的字段进行分词,然后当作做一个数组的查询字段(当前测试版本是使用js脚本进行插入的,一百万一次会比较慢); 当前本地库已经插入240万条带有calling分词的数据

#### JS执行代码

```
// 获取指定长度的数字随机数
function RndNum(n){
    var rnd="";
    for(var i=0;i<n;i++)
        rnd+=Math.floor(Math.random()*10);
    return rnd;
}

// 数组元素去重
Array.prototype.push2 =function(args){
    if(this.indexof(args) == -1){
        this.push(args);
    }
};
```

```
// 数组元素进行分词
Array.prototype.splitWord=function(str,len){
 if(len <= 0) len = 0;
 var size = str.length;
 if(size == 0) return;
 if(len >= size + 1) return;
 var temLen = 0;
 for(;temLen < size; temLen ++){</pre>
     if(temLen + len > size){
               continue;
    }
    var ele = str.substring(temLen,temLen + len);
    this.push2(ele);
 }
 this.splitWord(str,len + 1);
};
// 执行分词插入
db.ucCallRecord.find().forEach(function(item){
    var arr1 = new Array();
    arr1.splitWord(RndNum(11),1); // 11 位字符进行分词插入
    db.ucCallRecord.update({_id:item._id},{$set:
{calling:arr1, called:arr1, wireNumber:arr1}}, {upsert:true});
});
```

## 文档大小限制

- 1、索引关键字: 该字段的取值不能超过1024字节, 否则不能添加到一个索引中。
- 2、集合的最大所有个数: 64
- 3、索引名称长度:包括数据库于集合名称总共不超过125字符。
- 4、联合索引最大字段个数: 31
- 5、单个文档大小不能超过16M

## 查询速度比较

## 记录表信息:

/	Value		
"" ns	gzbsms.ucCallRecord		
i₃ size	27,471,725,878 (25.6 GiB) 48,000,000 (48.0 M) 572		
is count			
i avgObjSize			
ı storageSize	5,149,343,744 (4.8 GiB)		
™ capped	false		
⊳ 🖸 wiredTiger	{ 14 fields }		
in nindexes	12		
ı totalIndexSize	9,981,358,080 (9.3 GiB)		
	{ 12 fields }		
_id_	437,186,560 (437.2 M)		
iaz monthSetId_1 iaz calling_1 iaz called_1 iaz beginTime1 iaz duration_1	448,692,224 (448.7 M)		
	1,355,358,208 (1.4 G) 1,634,295,808 (1.6 G)		
	244,002,816 (244.0 M)		
	i₃ trunkld_1	148,099,072 (148.1 M)	
i₃ wireNumber_1	1,327,144,960 (1.3 G)		
i callingarr_1	950,657,024 (950.7 M)		
ः callRecord_beginTime_tenementId_id	909,975,552 (910.0 M)		
ः callRecord_direction_trunkld_idx	195,133,440 (195.1 M)		
callingarr_1_beginTime_1	1,804,140,544 (1.8 G)		
iæ ok	1		

## 查询条件

### 左前缀查询

#### 分词查询

 $\label{lem:cond} $$db.ucCallRecord.find({callingarr:'12345'}).sort({"beginTime":-1}).limit(100).explain('executionStats');$ 

查询 条件	左前缀	分词
12345	索引扫描: 94, 文档扫描: 353, 耗时: 3 ms,返回: 94	索引扫描: 77, 文档扫描: 77, 耗时: 1 ms,返回: 77
123	索引扫描: 13738, 文档扫描: 64900, 耗时: 974 ms,返回: 100	索引扫描: 100, 文档扫描: 100, 耗时: 23 ms,返回: 100
12	索引扫描: 147286, 文档扫描: 789842, 耗时: 6521 ms,返回: 100	索引扫描: 100,文档扫描: 100,耗时: 33 ms,返回: 100
1	索引扫描: 1073952, 文档扫描: 8814688, 耗时: 77368 ms,返回: 100	索引扫描: 100, 文档扫描: 100, 耗时: 1 ms,返回: 100

## 测试小结:

#### 左前缀匹配索引方式进行模糊查询

#### 优点

- 无需做业务上的修改,后期开发灵活,只需要查询时使用正则表达式即可
- 在查询越精确的数据速度越快,若没有查询到匹配的记录会返回很快,基本上都是毫秒级别
- 内存,存储压力较少

#### 缺点

• 当匹配到的记录越多是,返回数据越慢(因为需要对查询到的记录进行排序)

#### 分词方式进行模糊查询

#### 优点

• 数据按照索引顺序,进行精确匹配,查询速度很快

#### 缺点

- 空间换时间:数据大小增加
- 逻辑复杂: 需要对模糊匹配字段进行分词,同时需要添加数组索引, 在逻辑复杂度增加
- 操作不灵活: 当需求变更是, 若添加/删除模糊字段, 需要重新定义数据结构